



UNIVERSIDAD
SAN SEBASTIAN
Ilumina el futuro

SOLEMNE II

Informe de Análisis de Datos de Salud, Hábitos y Modelamiento Predictivo

Alan Silva

Universidad San Sebastián

Docente: Manuel Reveco Cabello

Asignatura: Minería de datos y Big data

Fecha: 29-05-2026

Índice

1	Problemática	3
2	Desarrollo de ejercicios	3
2.1	Preparativos del entorno y datos (ejercicio 1)	3
2.2	Manipulación de datos con Pandas (ejercicio 2)	3
2.3	Operaciones con NumPy (ejercicio 3)	4
2.4	Gráficos (ejercicio 4).....	4
2.5	Algoritmo Apriori (ejercicio 5)	6
2.6	Clustering con K-means (ejercicio 6).....	6
3	Anexos	8
3.1	Personas con IMC > 30 y Horas de ejercicio < 2.....	8

1 Problemática

El presente informe aborda el análisis de los hábitos de vida y parámetros de salud de un conjunto de 1.000 pacientes. El objetivo principal es aplicar técnicas de ingeniería de características, análisis estadístico y minería de datos (reglas de asociación y agrupamiento) para identificar patrones críticos relacionados con la obesidad, el sedentarismo y la distribución demográfica de los indicadores biomédicos.

2 Desarrollo de ejercicios

2.1 Preparativos del entorno y datos (ejercicio 1)

Se diseñó un script en Python que simula de manera aleatoria el comportamiento clínico de 1.000 registros, limitando las variables a rangos lógicos (Edad entre 18 y 80 años; IMC entre 15 y 40). El set de datos resultante fue exportado a la estructura datos_salud.csv y posteriormente cargado en memoria mediante la librería Pandas utilizando una semilla aleatoria (random_seed=57) para asegurar la reproducibilidad de los experimentos.

```
n = 1000
np.random.seed(57)

datos = {
    "ID": range(1, n + 1),
    "Edad": np.random.randint(18, 81, n),
    "Ciudad": np.random.choice(
        ["Puerto Varas", "Puerto Montt", "Llanquihue", "Concepción",
        "Temuco"], n
    ),
    "HorasEjercicio": np.round(np.random.uniform(0, 10, n), 1),
    "IMC": np.round(np.random.uniform(15, 40, n), 1),
    "Fuma": np.random.choice(["Sí", "No"], n),
    "Consumo": np.random.choice(["Pescado", "Verduras", "Frutas"], n),
    "Consume_Fruta": np.random.choice([0, 1], n, p=[0.35, 0.65]),
    "Consume_Verdura": np.random.choice([0, 1], n, p=[0.30, 0.70]),
}

df = pd.DataFrame(datos)
df.to_csv("datos_salud.csv", index=False, encoding="utf-8")
```

2.2 Manipulación de datos con Pandas (ejercicio 2)

Se inspeccionó la estructura inicial del dataset imprimiendo las primeras 10 filas para corroborar la correcta disposición de las columnas solicitadas (ID, Edad, Ciudad, HorasEjercicio, IMC, Fuma, Consumo).

Se aplicó una máscara para segmentar a la subpoblación con pacientes con un Índice de Masa Corporal de rango obeso ($IMC > 30$) que además registran niveles críticos de

inactividad física (*HorasEjercicio* < 2). El resultado de esta operación se puede encontrar en el Anexo 3.1.

```
pacientes = df[(df["IMC"] > 30) & (df["HorasEjercicio"] < 2)]
print(pacientes)

promedio_imc_por_ciudad = df.groupby("Ciudad")["IMC"].mean()
print(promedio_imc_por_ciudad)
```

Con el fin de descubrir sesgos o tendencias geográficas, se agruparon las observaciones por la variable Ciudad. Los promedios computados arrojaron una distribución homogénea en la muestra, situándose los centros urbanos evaluados en rangos generales sin desviaciones atípicas extremas entre sí.

Ciudad	Promedio IMC
Concepción	27.793365
Llanquihue	28.401554
Puerto Montt	26.611675
Puerto Varas	26.618779
Temuco	26.431183

2.3 Operaciones con NumPy (ejercicio 3)

Primero se extrajo la serie de datos HorasEjercicio transformándola en un arreglo nativo de NumPy mediante `.to_numpy()`. Luego se calculó el percentil 90 de las horas de ejercicio diario utilizando `np.percentile`. Este valor establece el umbral estadístico donde el 90% de la población analizada realiza un número igual o menor de horas de actividad física, aislando de esta manera al 10% de los pacientes más activos físicamente.

90º percentil de horas de ejercicio: 8.810000000000002

Finalmente, utilizando `MinMaxScaler`, se ejecutó el escalamiento de la variable IMC para comprimir matemáticamente todos los registros en un rango estricto entre 0 y 1, garantizando que el sesgo de escala nominal no afecte.

2.4 Gráficos (ejercicio 4)

Se graficó la frecuencia de edades de los 1.000 pacientes en un histograma, visualizándose una distribución uniforme a lo largo del rango muestral que valida metodológicamente la representatividad demográfica del set de datos.




Figura 1. Histograma de la edad de los pacientes

Luego, se evaluó la interacción conjunta situando el IMC en el eje horizontal y las Horas de Ejercicio en el eje vertical para inspeccionar visualmente la concentración de los pacientes de riesgo y perfiles activos.




Figura 2. Gráfico de dispersión entre IMC y horas de ejercicio

2.5 Algoritmo Apriori (ejercicio 5)

Se binarizaron las variables cualitativas transformando Consume_Fruta y Consume_Verdura al formato booleano. Se ejecutó el algoritmo Apriori parametrizando un soporte mínimo de 0.1 y una confianza mínima de 0.5.

Si observamos únicamente la Confianza y el indicador de Kulczynski (0.666963), se podría concluir erróneamente que existe una fuerte dependencia mutua en el comportamiento alimentario de los pacientes. Sin embargo, al analizar el archivo CSV completo, descubrimos lo siguiente:

1. **Alta probabilidad basal (Soporte Individual):** Al revisar el dataset completo de 1.000 registros, se observa que el porcentaje general de personas que consumen frutas de forma independiente es sumamente alto (por ejemplo, un 70%), y lo mismo ocurre con las verduras (75%).
2. **Independencia Estadística (Lift cercano a 1):** Este arroja un valor prácticamente igual a 1. Esto significa que el antecedente y el consecuente son estadísticamente independientes.
3. **El efecto de la aleatoriedad:** Que la confianza sea alta no se debe a que comer fruta *impulse* a comer verdura. Se debe a que, como casi todo el mundo en el dataset consume verduras de todas formas, cualquier subgrupo elegido al azar (incluyendo el de los consumidores de fruta) presentará una alta tasa de consumo de verdura.

antecedents	consequents	antecedent support	consequent support	lift	kulczynski
frozenset({'Consume_Fruta'})	frozenset({'Consume_Verdura'})	642	688	1,00295E+16	6,66963E+15
frozenset({'Consume_Verdura'})	frozenset({'Consume_Fruta'})	688	642	1,00295E+16	6,66963E+15

Tabla 1. Resultados del algoritmo Apriori

2.6 Clustering con K-means (ejercicio 6)

- 1 Se aislaron las dimensiones numéricas esenciales: Edad, IMC y HorasEjercicio.
- 2 Se aplicó la transformación StandardScaler para estandarizar los datos con media 0 y varianza 1.
- 3 Se entrenó el modelo K-Means fijando a k=3 clusters, utilizando la semilla random_state=57.
- 4 El volumen de pacientes se distribuyó de la siguiente manera:
 - Cluster 2: 381 pacientes.

- Cluster 1: 323 pacientes.
- Cluster 0: 296 pacientes.

Para visualizar los resultados de los clusters, primero se insertó el cluster correspondiente a la fila de cada persona, posteriormente, se agrupó por los clusters y se calculó el promedio de Edad, IMC y HorasEjercicio. Los resultados obtenidos se pueden interpretar de la siguiente manera:

Cluster 0 (Adultos Mayores Sedentarios - Rango Controlado): Presenta una edad promedio de 64.18 años, un IMC controlado de 24.31 y el nivel de ejercicio más bajo de todo el set de estudio (2.95 horas). Corresponde al grupo de la tercera edad que requiere planes de activación física adaptada.

Cluster 1 (Adultos Jóvenes Saludables / Activos): Edad promedio de 35.70 años, con un índice de masa corporal óptimo (21.30) y la tasa más alta de ejercicio (5.98 horas). Representa el perfil metabólicamente sano.

Cluster 2 (Adultos de Mediana Edad con Riesgo de Obesidad): Edad promedio de 47.88 años. A pesar de realizar actividad física (5.82 horas), su IMC promedio se sitúa críticamente en rangos de obesidad (34.38). Este segmento es de alto interés clínico prioritario, sugiriendo que su sobrepeso se vincula a factores nutricionales o genéticos externos al sedentarismo.

También, se pueden visualizar en un gráfico en 3D:




Figura 3. Gráfico en 3D de los clusters y centroides del K-means.

3 Anexos

3.1 Personas con IMC > 30 y Horas de ejercicio < 2

ID	Edad	Ciudad	HorasEjercicio	IMC	Fuma	Consumo	Consume_Fruta	Consume_Verdura
17	35	Puerto Montt		1.5	37.4 Sí	Pescado	1	1
39	31	Concepción		0.9	39.9 No	Verduras	1	1
86	37	Concepción		1.3	32.1 No	Verduras	1	1
94	49	Llanquihue		1.7	34.1 Sí	Verduras	1	1
112	71	Llanquihue		0.4	30.7 Sí	Pescado	1	1
138	61	Puerto Varas		0.7	36.8 No	Frutas	1	1
153	25	Concepción		1.1	36.4 No	Frutas	1	0
160	59	Puerto Varas		0.2	36.7 No	Pescado	1	0
181	57	Llanquihue		1.5	36.5 No	Pescado	1	0
182	43	Puerto Montt		0.2	36.8 No	Verduras	1	1
185	79	Puerto Varas		1.5	30.7 No	Verduras	0	1
188	60	Puerto Varas		0.9	30.3 Sí	Verduras	0	1
190	29	Puerto Montt		1.7	40 No	Verduras	1	1
200	52	Llanquihue		0.2	38.4 No	Pescado	0	1
223	51	Puerto Varas		0.2	39.3 Sí	Pescado	1	0
245	29	Puerto Varas		0.2	38.7 Sí	Frutas	1	1
256	67	Concepción		0.2	39 No	Frutas	0	0
262	37	Puerto Montt		1.6	38.6 No	Frutas	0	1
272	27	Puerto Varas		1.8	35.6 No	Pescado	1	1
293	62	Puerto Varas		1.2	38.9 Sí	Frutas	1	1
300	66	Concepción		0.5	31.9 No	Pescado	1	1
313	52	Puerto Varas		0.2	36.7 Sí	Pescado	1	1
327	18	Puerto Varas		1.2	39.9 No	Pescado	1	1
332	33	Puerto Montt		1.1	33.2 Sí	Pescado	1	1
337	44	Concepción		0.6	35.8 No	Verduras	1	0
342	57	Puerto Montt		0.8	38.4 No	Pescado	1	1
350	22	Puerto Varas		1.1	33.3 Sí	Pescado	0	1
379	72	Concepción		0.1	39.7 Sí	Verduras	0	0
401	53	Puerto Montt		0.6	36.4 No	Verduras	0	0
411	71	Temuco		0.7	35.6 No	Pescado	1	1
450	50	Puerto Montt		0	33.9 Sí	Verduras	0	1
453	39	Puerto Varas		1.2	39.8 Sí	Pescado	1	0
455	63	Llanquihue		0.1	31.3 Sí	Pescado	0	0
458	63	Llanquihue		0.6	36.4 Sí	Pescado	0	1
465	43	Puerto Montt		0.8	37.2 No	Pescado	1	1
495	19	Temuco		1.8	38.4 No	Pescado	1	1
514	45	Puerto Varas		0.3	37.6 No	Pescado	1	1
522	68	Temuco		1.5	31.7 No	Frutas	0	0
524	78	Puerto Montt		0.4	39.9 No	Frutas	1	1
525	53	Llanquihue		1.9	33.5 No	Verduras	0	1
528	63	Temuco		1.4	35.1 No	Pescado	0	1
567	41	Puerto Varas		1.1	33.6 Sí	Frutas	1	1
573	46	Puerto Montt		0.8	39.1 No	Verduras	1	1
587	22	Concepción		1.7	32.7 Sí	Pescado	1	0
595	23	Llanquihue		1.6	32.9 No	Frutas	0	0
598	76	Llanquihue		0.5	38.6 No	Pescado	1	1
612	20	Concepción		1.1	36.8 No	Pescado	0	1
646	60	Concepción		1.5	39.5 Sí	Frutas	1	1
708	57	Concepción		1.9	38.6 Sí	Frutas	1	1
730	56	Temuco		0.4	35.1 Sí	Verduras	0	1
731	21	Llanquihue		1.2	30.1 No	Verduras	0	1
741	70	Puerto Varas		0.8	32.8 No	Pescado	0	1
750	41	Puerto Varas		1.8	32 No	Verduras	0	1
753	24	Llanquihue		0.7	31.1 No	Pescado	1	0
772	21	Temuco		1.3	32.3 Sí	Pescado	1	1
796	68	Puerto Montt		1.6	35.9 No	Pescado	1	1

815	51 Temuco	0.6	32.9	Sí	Pescado	0	1
821	28 Puerto Montt	1.7	30.5	No	Frutas	1	0
857	50 Puerto Varas	0.7	36.5	No	Pescado	1	1
861	77 Llanquihue	0.7	35.8	Sí	Verduras	1	0
887	42 Llanquihue	1.6	38.3	No	Verduras	1	1
917	72 Llanquihue	0.9	39.2	No	Frutas	1	0
930	75 Llanquihue	0.8	36.7	No	Pescado	1	0
943	55 Llanquihue	0.3	39.9	Sí	Verduras	0	0
953	60 Concepción	1.9	34.5	No	Verduras	1	0
965	39 Concepción	0.3	31.3	No	Verduras	1	1
970	25 Temuco	0.3	32.6	No	Frutas	1	1
990	19 Llanquihue	1.7	33.5	No	Frutas	0	1
998	45 Puerto Varas	0.6	31.9	Sí	Frutas	1	0

Tabla 2. Personas con IMC > 30 y Horas de ejercicio < 2